

基因组选择中的模型阶梯与评估口径： “ML 能否打败 BLUP”的一次可复现检验

Model Ladders and Evaluation Protocols in Genomic Selection: A Reproducible Test of “Can ML Beat BLUP?”

短文 (short paper) · 2026-09-20 · 单机 CPU (4 核) 全流程 9.6 分钟 · 全部结果 3 seeds

摘要 —— 针对“机器学习/LLM 能否在基因组选择 (GS) 中打败 BLUP”这一常被观点化讨论的问题，我们构建了一个固定的实验阶梯 (L0 系谱BLUP → L1 GBLUP → L2 梯度提升 → L3 加权先验演示) 并在三种严格区分的评估口径 (随机5折CV、留家系代理、前向代理) × 3 个随机种子下实测。主选的 Cleveland et al. 2012 PIC 猪数据集完整版在实验环境的网络策略下不可得，按预先约定的规程降级为 BGLR wheat 公开数据 (599 系 × 1,279 标记 × 4 环境性状，含系谱 A 矩阵)，并附真实猪基因型 (3,534 × 52,843，仅 t1 性状) 的补充分析。结果：基因组信息相对系谱的增益在所有口径下稳健 (随机CV +0.060，留家系 +0.056)；梯度提升仅在随机CV下超过 GBLUP (0.472 vs 0.438)，在留家系 (0.186 vs 0.220) 与前向 (0.229 vs 0.290) 口径下反转；评估口径造成的 r 变化 (约 0.25) 比模型选择 (约 0.03) 大近一个数量级。结论：在本数据与口径下，非线性 ML 的“优势”主要来自随机CV可利用的家系结构泄漏；GS 研究的第一优先级是评估口径而非模型形式。

关键词：基因组选择 · GBLUP · 梯度提升 · 交叉验证泄漏 · 留家系验证 · 可复现性

1 研究问题与假设

核心问题：给定同等信息与算力预算，非线性 ML (以规范固定超参的梯度提升为代表) 能否稳健超过线性收缩类方法 (系谱BLUP / GBLUP)？我们预先登记了三条可证伪假设与一个泄漏哨兵：H1 标记信息相对系谱有真实增益 ($L1 > L0$ ，且在难口径下保持)；H2 在 $n \approx 600-3,500$ 、以加性遗传架构为主的数据上，L2 相对 L1 无稳健增益 (收缩先验与小样本回归匹配)；H3 随机CV 相对家系感知口径显著虚高，且口径效应 $\geq$ 模型效应。哨兵：任何模型若出现留家系 $r \geq$ 随机CV r ，先怀疑代码泄漏而非“模型强”。

2 数据 (含诚实声明)

主选与降级：主选为 Cleveland et al. 2012 (G3) 公开的 PIC 猪数据集 (3,534 头、52,843 SNP、5 性状、系谱 6,473)。实验环境出站网络仅放行 GitHub/PyPI；PMC 直链、OUP、figshare、Dryad、Zenodo、Wayback 共 4 条获取路径全部被代理 403 拦截 (notebook 内保留现场重试的 stderr 证据)；唯一可达的 GitHub 镜像 (QuantGen/G2P-Datasets, 00070) 为 curated 版，仅含 t1 单性状且无系谱，性状数偏差 $80\% > 10\%$ ，按预定规程判定“不得作为主选”。因此正式实验降级为 BGLR wheat (CIMMYT 599 自交系 × 1,279 DaRT 标记，4 个环境的标准化籽粒产量作为 4 个性状，附系谱推导的 A 矩阵；来源 gdlc/BGLR-R@de839cf)；同时以 补充分析 身份保留真实猪基因型 (3,534 × 52,843 + t1，来源 QuantGen/G2P-Datasets@a7bf58a；镜像已预填补缺失基因型，非整数剂量占 0.13%)。

预处理 (两套数据同一流程)：缺失基因型列均值填充 → $MAF < 0.01$ 位点剔除 (wheat 1,279 → 1,278；pig 52,843 → 50,436) → 中心化。核验：wheat 全部维度核对通过；pig 核验明确失败并全程降级标注。数据文件 SHA-256 与来源 commit 记录于 notebook。

3 方法

实验阶梯：L0 系谱BLUP = 系谱 A 矩阵上的核岭回归 (仅 wheat；pig 无系谱，声明跳过)；L1 GBLUP = $G = X_c X_c^T / k$ 上的核岭回归， $\alpha \in \{0.1, 0.3, 1, 3, 10\}$ 由训练集内 3 折按 r 选取 (防泄漏)；L2 梯度提升 (300 棵树、深度 3、学习率 0.05、行采样 0.8)；L3 加权岭 = 随机 20% 位点权重 × 2 的加权 GBLUP——“功能先验”的机制演示，权重为声明的占位而非真实功能注释；L4 (纯 LLM 直接建模基因型) 不实现，理由见第 6 节。

三种评估口径 (分开报告，禁止混合)：①随机 5 折 CV (作为会虚高的对照存在)；②留家系代理：无父系 ID，按预定规程以 G 矩阵层次聚类 10 组代替家系，GroupKFold(5)；③前向代理：两套数据均无世代/批次信息，以“留出与其余群体平均基因组关系最低的聚类 ($\geq 20\%$ 样本)”近似“老代训练 → 新代预测”的外推难度——声明：这是结构外推代理，不是时间切分。指标：predictive ability $r = \text{corr}(\text{预测}, \text{真实表型})$ ；bias = 真实对预测回归的斜率 (理想 ≈ 1)；Top-10% 命中率。各折 out-of-fold 预测合并后计算；全流程 seeds = {0, 1, 2}。

工程与自检：GBLUP 双层等价性自检——核侧与标记侧 Ridge 在逐折同 α 下 $\max|\Delta r| = 0.0038$ (≤ 0.02 闸门，针对 G 构造/对齐 bug)，RidgeCV 自选 α 的策略敏感性 $\max|\Delta r| = 0.063$ (α 准则差异在弱信号性状上放大，非实现错误，如实报告)。L2 引擎按探针实测决策：sklearn GradientBoosting 在猪全量 SNP 上单次拟合实测外推 17.8 分钟/次 (不可行，声明禁用)，改用同超参的 LightGBM 直方图实现；规范原版 sklearn GBR 在 wheat 上以参照检查在

场（与 LightGBM 差 ≤ 0.048 ）；猪 L2 采用无表型参与的 1/5 等距抽稀（全量 SNP 参照检查 $|\Delta r| = 0.026$ ，在弱信号量级内）。

4 结果

模型	随机5折CV	留家系代理	前向代理
L0 系谱BLUP	0.377 ± 0.043	0.164 ± 0.106	0.126 ± 0.087
L1 GBLUP	0.438 ± 0.071	0.220 ± 0.059	0.290 ± 0.094
L2 梯度提升	0.472 ± 0.058	0.186 ± 0.077	0.229 ± 0.118
L3 加权岭(占位)	0.436 ± 0.070	0.221 ± 0.059	0.293 ± 0.100

表 1 wheat（正式）：predictive ability r （4 性状 × 3 seeds 的 mean ± std）

模型	随机5折CV	留家系代理	前向代理
L1 GBLUP	0.056 ± 0.016	-0.005 ± 0.006	-0.065 ± 0.000
L2 梯度提升	0.073 ± 0.001	-0.002 ± 0.010	-0.043 ± 0.015
L3 加权岭(占位)	0.056 ± 0.017	-0.005 ± 0.006	-0.064 ± 0.004

表 2 pig t1（补充；仅 1/5 性状、无系谱，L0 跳过）： r （3 seeds mean ± std）。各模型 $r \approx 0.05\text{--}0.09$ ，信号极弱；核/标记两侧 $|\Delta r|=0.001$ 排除对齐错误，弱信号为性状属性。

H1 成立：wheat 上 GBLUP 相对系谱BLUP 的增益为随机CV +0.060、留家系 +0.056——基因组信息在难口径下保持优势。H2 成立：梯度提升仅在随机CV下领先（0.472 vs 0.438），留家系（0.186 vs 0.220）与前向（0.229 vs 0.290）口径下均反转；猪补充分析在弱信号量级下同向。L3 与 L1 相当，说明加权机制的收益取决于权重质量。H3 成立：随机CV 相对留家系的平均虚高 $\Delta r \approx +0.25$ （wheat）/ +0.07（pig t1），而 wheat 随机CV 下 L1↔L2 的模型差距仅 0.03。泄漏哨兵在两套数据上均通过（留家系 $r <$ 随机CV r ）。bias 佐证同一机制：wheat GBLUP 的回归斜率由随机CV 的 0.94 降至留家系口径的 0.55（预测过度离散加剧）；Top-10% 命中率随机CV 下为 0.30（随机基线 0.10）。




图 1 实验阶梯 × 三口径（灰圈 = 单性状均值；误差棒 = 跨 seed std）。上：wheat 正式；下：pig t1 补充。




图 2 “虚高差距”哑铃图：随机CV（蓝） 留家系代理（橙）。L2 的差距（wheat +0.29）大于 GBLUP（+0.22）：越灵活的模型越吃口径红利。

5 结论

在本数据与口径下：(i) 标记信息相对系谱的增益真实且在难口径下保留；(ii) 固定超参的非线性 ML 没有稳健打败 GBLUP——其领先只出现在会虚高的随机CV口径，且其虚高幅度大于线性方法，提示“ML 打败 BLUP”类结论的相当一部分可能是评估口径的产物；(iii) 口径选择对 r 的影响比模型选择大近一个数量级。对实践者的操作性含义：在报告任何 GS 模型对比前，必须先给出家系感知与前向两类口径的结果与泄漏哨兵。

6 为何不做“纯 LLM 直接建模基因型”（L4）

(i) SNP 矩阵是无语法结构的高维数值表，LLM 的归纳偏置（序列共现、离散 token 语义）在匿名化、LD 冗余的芯片位点上没有可迁移先验；(ii) $n \approx 600-3,500$ 的监督信号不足以支撑大参数模型学到超越线性收缩的结构，反而更易过拟合家系结构——恰是随机CV虚高的来源；(iii) 在近似无穷小效应的加性架构下，岭/GBLUP 即相应高斯先验的后验均值，“打败 BLUP”需要真实且可学习的非加性/稀疏结构，而本实验 L2/L3 的实测未显示这类结构。更有希望的切入点：用 LLM 从功能注释/文献生成位点先验权重，替换 L3 的占位权重。

7 局限

① L3 权重为演示用占位（随机 20% 位点 $\times 2$ ），不构成“功能先验有效”的证据；② 前向与留家系均为声明的代理口径（无真实世代/父系 ID）；③ 数据集与中国生产群体（如杜长大体系）在品种、LD 结构、性状定义上均不同，数字不可直接外推；④ 猪补充分析仅 1 个弱信号性状、镜像经预填补；单软件栈、未做统计显著性检验；L2 未调参（规范固定超参，本身即一种保守设定）。

8 下一步与改进

数据：在可达网络下获取 Cleveland 完整版（5 性状 + 系谱 6,473），恢复猪为主选：真实父系 GroupKFold、系谱世代前向切分、5 性状全阶梯（notebook 的核验 cell 已预留切回路径）；进一步接入国内生产群体数据以检验外推。方法：L3 以真实功能注释（如 FAANG/PigGTEx 分区）替换占位权重，对照 BayesRC/MultiBLUP；补充 Bayesian alphabet (BayesB/R) 与显性/上位性核作为非加性基线；DL 基线 (MLP/1D-CNN) 在同一三口径协议下复测。评估与工程：对折 $\times$ seed 做配对 bootstrap 给出置信区间与显著性；真实时间轴前向验证；把“泄漏哨兵 + 双层等价性 + 格子数守恒”固化为预注册协议与 CI 自检；多数据集重复以评估结论迁移性。